

Lista 02 - MQ

Martha Gaudencio

2026-02-01

```
#MQ101 - Lista 02
#Nome: Martha Gaudencio da Silva
#Data: 22/10/2025
#Descrição: Tipos de variáveis e estatísticas descritivas
```

#1 - Preparação do ambiente

```
library(tidyverse)
```

```
## — Attaching core tidyverse packages ————— tidyverse 2.0.0 —
## ✓ dplyr     1.1.4      ✓ readr     2.1.6
## ✓ forcats   1.0.1      ✓ stringr   1.6.0
## ✓ ggplot2   4.0.1      ✓ tibble    3.3.1
## ✓ lubridate 1.9.4      ✓ tidyr    1.3.2
## ✓ purrr    1.2.1
## — Conflicts ————— tidyverse_conflicts() —
## ✘ dplyr::filter() masks stats::filter()
## ✘ dplyr::lag()   masks stats::lag()
## i Use the conflicted package (<http://conflicted.r-lib.org/>) to force all conflicts to be
## come errors
```

```
options(scipen = 999)
```

#2 - Base de dados

```
dados <- read.csv(file.choose())
glimpse(dados)
```

```
## Rows: 10,000
## Columns: 13
## $ id                  <chr> "P00001", "P00002", "P00003", "P00004", "P00005", "P...
## $ sexo                <chr> "M", "F", "F", "F", "F", "F", "F", "F", "M...
## $ escolaridade        <chr> "Medio", "Medio", "Medio", "Medio", "Medio"...
## $ anos_estudo         <int> 10, 9, 9, 10, 11, 11, 10, 8, 15, 11, 6, 7, 5, 4, 10, ...
## $ rede_escolar         <chr> "privada", "pública", "pública", "pública"...
## $ municipio           <chr> "Santos", "Dourados", "Várzea Grande", "Curitiba", ...
## $ UF                  <chr> "SP", "MS", "MT", "PR", "RJ", "SP", "SC", "SP"...
## $ idade                <int> 39, 30, 31, 44, 26, 51, 47, 48, 25, 53, 23, 27, 35, ...
## $ faltas_esc            <int> 0, 0, 1, 0, 1, 0, 1, 0, 0, 0, 0, 2, 0, 0, 0...
## $ tempo_estudo_h       <dbl> 2.3, 6.6, 8.8, 4.2, 3.7, 4.9, 0.2, 1.9, 14.4, 3.3, 3...
## $ pressao_sistolica    <int> 110, 109, 121, 131, 134, 124, 139, 124, 132, 134, 13...
## $ diagnostico          <chr> "sem", "sem", "sem", "sem", "sem", "HAS", "sem", "se...
## $ plano_saude          <chr> "privado", "privado", "nenhum", "nenhum", "SUS", "pr...
```

```
summary(dados)
```

```
##      id          sexo        escolaridade      anos_estudo
## Length:10000    Length:10000    Length:10000    Min.   : 4.00
## Class :character Class :character Class :character 1st Qu.: 8.00
## Mode  :character Mode  :character Mode  :character Median :11.00
##                                         Mean   :10.74
##                                         3rd Qu.:13.00
##                                         Max.   :20.00
## 
##      rede_escolar      municipio          UF          idade
## Length:10000    Length:10000    Length:10000    Min.   :18.00
## Class :character Class :character Class :character 1st Qu.:31.00
## Mode  :character Mode  :character Mode  :character Median :40.00
##                                         Mean   :40.39
##                                         3rd Qu.:49.00
##                                         Max.   :80.00
## 
##      faltas_esc     tempo_estudo_h  pressao_sistolica diagnostico
## Min.   :0.0000  Min.   : 0.000  Min.   :85.0    Length:10000
## 1st Qu.:0.0000  1st Qu.: 2.800  1st Qu.:112.0   Class :character
## Median :0.0000  Median : 5.000  Median :122.0   Mode  :character
## Mean   :0.2346  Mean   : 6.122  Mean   :122.2
## 3rd Qu.:0.0000  3rd Qu.: 8.200  3rd Qu.:131.0
## Max.   :3.0000  Max.   :34.300  Max.   :175.0
## 
##      plano_saude
## Length:10000
## Class :character
## Mode  :character
## 
```

#Número de colunas: 13; número de Linhas: 10.000.

#Classes das variáveis: qualitativas e numéricas

#Não existem NA

3 - Classificação de variáveis

3.1 - Tipo teórico de cada variável

#Sexo: qualitativa nominal binária

#Escolaridade: qualitativa ordinal

#Anos de estudo: quantitativa discreta

#Rede escolar: qualitativa nominal binária

#3.2 Coerência entre tipo teórico e classe:

```
dados <- dados |>
  mutate(
    sexo = factor(sexo),
    rede_escolar = factor(rede_escolar),
    plano_saude = factor(plano_saude),
    diagnostico = factor(diagnostico),
    escolaridade = factor(escolaridade,
      levels = c("Fundamental", "Medio", "Superior"),
      ordered = TRUE)
  )
str(dados)
```

```
## 'data.frame': 10000 obs. of 13 variables:
## $ id           : chr "P00001" "P00002" "P00003" "P00004" ...
## $ sexo         : Factor w/ 2 levels "F","M": 2 1 1 1 1 1 1 1 1 1 ...
## $ escolaridade : Ord.factor w/ 3 levels "Fundamental"<...: 2 2 2 2 2 2 1 1 3 2 ...
## $ anos_estudo  : int 10 9 9 10 11 11 10 8 15 11 ...
## $ rede_escolar : Factor w/ 2 levels "privada","pública": 1 2 2 2 2 2 2 2 2 2 ...
## $ municipio    : chr "Santos" "Dourados" "Várzea Grande" "Curitiba" ...
## $ UF           : chr "SP" "MS" "MT" "PR" ...
## $ idade         : int 39 30 31 44 26 51 47 48 25 53 ...
## $ faltas_esc   : int 0 0 1 0 1 0 1 0 1 0 ...
## $ tempo_estudo_h : num 2.3 6.6 8.8 4.2 3.7 4.9 0.2 1.9 14.4 3.3 ...
## $ pressao_sistolica: int 110 109 121 131 134 124 139 124 132 134 ...
## $ diagnostico  : Factor w/ 4 levels "DM","HAS","outros",...: 4 4 4 4 4 2 4 4 4 4 ...
## $ plano_saude   : Factor w/ 4 levels "ambos","nenhum",...: 3 3 2 2 4 3 4 4 3 2 ...
```

#3.3 Registre, em comentários, por que cada variável é daquele tipo

#Sexo é qualitativa nominal porque se trata de uma informação não-numérica e que #apenas dá nome à categoria, no caso, feminino ou masculino, sendo aqui também #binária. O mesmo vale para rede escolar. Já escolaridade é também qualitativa, #mas ordinal, porque existe uma ordem que se segue em continuidade. Por fim, #anos de estudo é numérica categórica pois a base considera apenas números #inteiros.

#4 - Variáveis Qualitativas

#4.1 - Frequências absolutas e relativas

```
tab_plano <- table(dados$plano_saude)
prop_plano <- prop.table(tab_plano)
cbind(FA = tab_plano, FR = round(100 * prop_plano, 1))
```

```
##           FA   FR
## ambos      634  6.3
## nenhum    1868 18.7
## privado   2474 24.7
## SUS       5024 50.2
```

#SUS é a moda, porque é a que mais se repete. E a proporção dominante é de #50,2% do SUS.

#4.2 - Gráfico de barras

```
install.packages("ggplot2")
```

```
## Warning: o pacote 'ggplot2' está em uso e não será instalado
```


```
library(ggplot2)
install.packages("dplyr")
```

```
## Warning: o pacote 'dplyr' está em uso e não será instalado
```

```
library(dplyr)


dados |>
  count(plano_saude) |>
  ggplot(aes(x = plano_saude, y = n)) +
  geom_col() +
  labs(x = "Plano de saude", y = "Frequencia",
       title = "Distribuição de plano de saúde")
```

Distribuição de plano de saúde



#4.3 - Barras ordenadas

```
dados |>
  count(escolaridade) |>
  ggplot(aes(x = escolaridade, y = n)) +
  geom_col() +
  labs(x = "Escolaridade (ordem substantiva)", y = "Frequencia")
```



#Como trata-se de uma variável ordinal, manter a ordem das variáveis permite visualizar a informação com mais sentido, no caso percebendo que o ensino superior corresponde ao 3º nível e possui menos membros da amostra com este grau em comparação com os que possuem fundamental e médio. Já o gráfico de barras em variáveis não ordinais como a do plano de saúde permite ver qual possui mais aderência indo do menor para o maior sem que seja uma sequência ordinal das variáveis.

#5 - Variáveis quantitativas

#5.1 Tendência central e dispersão

```
sumario_idade <- dados |>
  summarise(
    n = sum(!is.na(idade)),
    media = mean(idade, na.rm = TRUE),
    mediana= median(idade, na.rm = TRUE),
    min = min(idade, na.rm = TRUE),
    max = max(idade, na.rm = TRUE),
    dp = sd(idade, na.rm = TRUE)
  )
sumario_idade
```

	n	media	mediana	min	max	dp
## 1	10000	40.3948	40	18	80	12.48622

```
sumario_pressao_sistolica <- dados |>
  summarise(
    n = sum(!is.na(pressao_sistolica)),
    media = mean(pressao_sistolica, na.rm = TRUE),
    mediana= median(pressao_sistolica, na.rm = TRUE),
    min = min(pressao_sistolica, na.rm = TRUE),
    max = max(pressao_sistolica, na.rm = TRUE),
    dp = sd(pressao_sistolica, na.rm = TRUE)


  )
sumario_pressao_sistolica
```

```
##      n    media mediana min max      dp
## 1 10000 122.1863     122   85 175 14.05137
```

#Tanto a média quanto a mediana de idade e de pressão sistólica estão simétricas, evidenciando que os dados não possuem valores que destoam muito da média para interferir na mediana.


#5.2 Histograma e boxplot

```
ggplot(dados, aes(x = idade)) +
  geom_histogram(bins = 20) +
  labs(title = "Histograma de Idade")
```




```
ggplot(dados, aes(y = idade)) +  
  geom_boxplot() +  
  labs(title = "Boxplot de Idade")
```

Boxplot de Idade




```
ggplot(dados, aes(x = pressao_sistolica)) +  
  geom_histogram(bins = 20) +  
  labs(title = "Histograma de pressao sistolica")
```

Histograma de pressao sistolica



```
ggplot(dados, aes(y = pressao_sistolica)) +  
  geom_boxplot() +  
  labs(title = "Boxplot de pressao sistolica")
```

Boxplot de pressao sistolica



```
#0 Histograma de idade tem a cauda ao lado direito, permite visualizar a
#moda na idade 40, o que converge com a média apresentada anteriormente.
#0 boxPlot de idade tem a mediana no 40, também conforme mostrado e permite
#visualizar os dados discrepantes das idades em torno de 80 anos, além de
#mostrar que o 1º quartil está em torno de 30 e o 3º quartil está em torno de
#50 anos.
```

```
#Já o gráfico de pressão sistólica permite visualizar que os maiores valores
#estão nas proximidades de 125, valor próximo à média e mediana de 122. O
#histograma possui uma simetria, ao contrário da idade. O boxplot apresenta
#também a mediana de 125 e os valores destoantes na faixa de 175, também
#permitindo visualizar os quartis.
```

#6 - Tabelas cruzadas

#6.1 - Cruzando duas qualitativas

```
tab_cross <- table(dados$diagnostico, dados$plano_saude)
tab_cross
```

```
##
##          ambos nenhum privado   SUS
##  DM        6      21      18    44
##  HAS       77     227     300   626
##  outros     35     112     163   302
##  sem      516    1508    1993  4052
```

```
round(100 * prop.table(tab_cross, margin = 2), 1)
```

```
## ambos nenhum privado SUS
## DM      0.9    1.1    0.7  0.9
## HAS     12.1   12.2   12.1 12.5
## outros   5.5    6.0    6.6  6.0
## sem     81.4   80.7   80.6 80.7
```

#No SUS, o mais prevalente é sem diagnóstico (80,7%), seguido de HAS (12,5%).
#Na rede privada, o mais prevalente é sem também (80,6%), seguido de HAS (12,1%).
#A mesma prevalência se repete em quem possui ambos e nenhum.

#6.2 - Resumo de quantitativa por grupo

```
dados |>
  group_by(sexo) |>
  summarise(
    n = n(),
    media_idade = mean(idade, na.rm = TRUE),
    dp_idade = sd(idade, na.rm = TRUE),
    mediana_idade = median(idade, na.rm = TRUE)
  )
```

```
## # A tibble: 2 × 5
##   sexo      n media_idade dp_idade mediana_idade
##   <fct> <int>     <dbl>     <dbl>        <dbl>
## 1 F        5192     40.3     12.5         40
## 2 M        4808     40.5     12.4         40
```

```
dados |>
  group_by(escolaridade) |>
  summarise(
    n = n(),
    media_idade = mean(idade, na.rm = TRUE),
    dp_idade = sd(idade, na.rm = TRUE),
    mediana_idade = median(idade, na.rm = TRUE)
  )
```

```
## # A tibble: 3 × 5
##   escolaridade      n media_idade dp_idade mediana_idade
##   <ord>       <int>     <dbl>     <dbl>        <dbl>
## 1 Fundamental    3399     40.2     12.4         40
## 2 Medio          4056     40.5     12.6         40
## 3 Superior       2545     40.4     12.5         40
```

```
#Em relação à idade por sexo, há uma semelhança na amostra. A média de homens
#e mulheres é próxima (40,5 e 40,3, respectivamente), com a mesma mediana de 40.
#Na escolaridade, a mediana de 40 se repete pois é a mesma amostra, sendo que
#a média de idade para superior, médio e fundamental também estão na faixa dos
#40 anos. Os desvios-padrão de ambos os grupos também mantém-se próximas pela
#lógica.
```

#7 - Valores ausentes e outliers

#7.1 - Ausentes

```
colSums(is.na(dados))
```

```
##          id        sexo      escolaridade    anos_estudo
##          0           0           0           0
##  rede_escolar      municipio          UF       idade
##          0           0           0           0
##  faltas_esc     tempo_estudo_h  pressao_sistolica  diagnostico
##          0           0           0           0
##  plano_saude
##          0
```

#A base de dados não retornou valores de células vazias, que seriam os NA.

#7.2 - Outliers

```
Q <- quantile(dados$tempo_estudo_h, probs = c(.25, .75), na.rm = TRUE)
IQRv <- IQR(dados$tempo_estudo_h, na.rm = TRUE)
lim_inf <- Q[1] - 1.5 * IQRv
lim_sup <- Q[2] + 1.5 * IQRv
subset_out <- dados |>
  filter(tempo_estudo_h < lim_inf | tempo_estudo_h > lim_sup)
nrow(subset_out); head(subset_out)
```

```
## [1] 348
```

```
##      id sexo escolaridade anos_estudo rede_escolar      municipio UF idade
## 1 P00033   F     Medio        11  privada    Blumenau  SC  63
## 2 P00037   M    Superior       15  privada    Pelotas  RS  44
## 3 P00067   M    Superior       14  pública    São Luís  MA  44
## 4 P00086   F    Superior       18  privada Imperatriz  MA  31
## 5 P00095   F    Superior       15  pública Rio de Janeiro  RJ  55
## 6 P00183   M    Superior       16  privada Duque de Caxias  RJ  37
##  faltas_esc tempo_estudo_h  pressao_sistolica diagnostico plano_saude
## 1          0        19.4            132      sem      SUS
## 2          0        17.6            133      sem      SUS
## 3          0        16.9            111    outros  privado
## 4          1        18.0            126      sem     ambos
## 5          2        21.3            136      HAS      SUS
## 6          1        18.6            116      sem    nenhum
```

```
#Essa amostra possui 348 outliers. Esses dados são informações válidas, pois
#mesmo que destoem dos demais permitem interpretar o que motiva esses casos
#variados, que podem ser desde preenchimento incorreto até variáveis
#explicativas dentro das políticas públicas.
```

#8. Exercícios aplicados (educação e saúde)

#8.1 - Educação

#Distribuição de rede escolar


```
tab_rede <- table(dados$rede_escolar)
prop_rede <- prop.table(tab_rede)
cbind(FA = tab_rede, FR = round(100 * prop_rede, 1))
```

```
##          FA   FR
## privada 2796 28
## pública 7204 72
```

#Gráfico boxplot

```
ggplot(dados, aes(x = escolaridade, y = tempo_estudo_h, fill = escolaridade)) +
  geom_boxplot() +
  labs(title = "Boxplot de Tempo de Estudo por Escolaridade",
       x = "Nível de Escolaridade",
       y = "Horas de Estudo")
```

Boxplot de Tempo de Estudo por Escolaridade



#Interprete


#A frequência absoluta é maior na rede pública, representando 72% da amostra #em contraposição com 28% da privada. Quanto ao boxplot de tempo de estudo #por escolaridade, este evidencia que há sim um padrão monotônico que é #crescente: as medianas vão crescendo logicamente, assim como os percentis #mostrados. Ainda que haja valores discrepantes, estes também sobem, o que é #lógico visto que uma escolaridade maior exige um tempo de estudo proporcional.

#8.2 - Saúde

#Pressão sistólica - histograma e informações

```
ggplot(dados, aes(x = pressao_sistolica)) +
  geom_histogram(bins = 20) +
  labs(title = "Histograma de Pressão Sistólica",
       x = "Pressão Sistólica (mmHg)",
       y = "Frequência")
```

Histograma de Pressão Sistólica




```
dados |>
  summarise(
    media = mean(pressao_sistolica, na.rm = TRUE),
    mediana = median(pressao_sistolica, na.rm = TRUE),
    dp = sd(pressao_sistolica, na.rm = TRUE)
  )
```

```
##      media mediana      dp
## 1 122.1863     122 14.05137
```

#Cruzamento diagnóstico e plano de saúde

```
ggplot(dados, aes(x = plano_saude, fill = diagnostico)) +
  geom_bar(position = "fill") +
  labs(x = "Plano de saúde",
       y = "Proporção",
       title = "Distribuição de diagnósticos por plano de saúde")
```

Distribuição de diagnósticos por plano de saúde



#Interprete

#Em todos os planos prevalecem respectivamente sem diagnóstico, HAS, outros e
#DM.